Stuff+ calibrado al Harp Helú: documento técnico

Equipo: Paulina Garza Allende, Othoniel Reyes Camacho, Andrea Guerra y Jose Rodrigo Dumas Avalos

Resumen

Construimos un sistema Stuff+ para la LMB que mide cuánto vale un pitcheo por su física al soltarlo y cuánto de ese valor sobrevive a 2,240 m, en el Estadio Alfredo Harp Helú. Tiene tres capas sobre 629,616 pitcheos Trackman de 2024 a 2026: Stuff+ (física de release), Location+ (ubicación, count y manos) y Pitching+ (ambas). Las tres usan la escala 100 + 10·z.

Fuera de muestra, Pitching+ agregado por pitcher correlaciona r = 0.56 con el run value real de 2026, contra r = −0.26 del baseline del reto (xRV medio por count), y Stuff+ es estable año a año (r = 0.61 a 0.68, contra 0.23 a 0.29 de los resultados). H1, H3 y H4 se confirman; H2 no se sostiene. En el Harp Helú la recta del mismo pitcher pierde 4.8 pulgadas de bote y 22 puntos de Stuff+, el slider 9, y el changeup casi duplica sus jonrones por pitcheo.

1. Marco teórico

Un Stuff+ responde cuánto valor esperado genera un pitcheo solo por su velocidad, rotación, movimiento y punto de salida. Separarlo del resultado observado importa porque el resultado de una bola en juego depende en gran parte del fildeo: McBride (2026) muestra con valores de Shapley que el ERA sobreacredita al pitcher en 39 %. Por eso nuestros objetivos son eventos que el pitcher controla (swing, whiff, strike cantado, calidad de contacto esperada) y no hits u outs realizados.

1.1 Física de la altitud

El arrastre y la fuerza Magnus son proporcionales a la densidad del aire ρ (Nathan, 2008):

$$F_D = ½ \cdot \rho \cdot C_D \cdot A \cdot v^2 F_M = ½ \cdot \rho \cdot C_L \cdot A \cdot v^2$$

A 2,240 m la densidad es cerca de 20 % menor que al nivel del mar. Menos arrastre significa que la pelota conserva velocidad; menos Magnus, que la rotación produce menos movimiento. Para el pitcher pesa más lo segundo, y para el bateador, que la pelota bateada viaja más lejos. Richardson (2014) estima en ligas menores que la ofensiva sube con la altitud, pero su muestra llega a unos 1,570 m, así que no extrapolamos sus pendientes al Harp Helú.

1.2 Hipótesis

Hipótesis	Enunciado	Prueba con datos LMB
H1	En altitud hay menos movimiento por Magnus	IVB y HB del mismo pitcher y tipo de pitcheo entre parques
H2	El changeup gana valor relativo en altitud	Delta de Stuff+ por tipo y resultados reales (contacto duro, jonrones)
H3	Los pitchers de rodados valen más en altitud	Valor del rodado contra el elevado por parque, con EV y ángulo fijos
H4	El spin solo no basta; importa la forma	Modelo con solo velocidad y spin contra forma completa, en holdout por pitcher

2. Datos

ISAC entregó 635,002 pitcheos Trackman de 2024, 2025 y la primera mitad de 2026 (2,127 juegos, 1,134 pitchers, IDs anonimizados). Tras la limpieza quedan 629,616: se excluyen `PitchCall` indefinidos, extensiones fuera de 3 a 8.5 pies y velocidades menores a 60 mph; `PlateLocHeight` igual a 0 se trata como faltante; `is_hit_by_pitch` (siempre 0) se recalcula desde `PitchCall`; los zurdos se espejan para que el movimiento horizontal tenga el mismo signo. El 76 % de los pitchers lanzó en al menos dos categorías de altitud, lo que permite comparar al mismo pitcher en distintos ambientes.

Identificación del Harp Helú. Los datos no traen estadio, solo tres categorías de altitud. Reconstruimos los equipos con los pitchers que lanzan juntos y calculamos el récord de cada uno. El equipo con mejor récord en 2024 (72-20) y 2025 (68-21), local en un parque Extreme, coincide con los Diablos Rojos, campeones de ambas temporadas; sus 128 juegos de local son el Harp Helú. Con las tablas de posiciones nombramos a los 20 equipos y su estadio. Es una inferencia nuestra, no confirmada por ISAC. Los datos tampoco traen corredores, fecha, umpire ni clima.

3. Decisiones de modelado

Arquitectura. Usamos gradient boosting (LightGBM). Captura interacciones no lineales entre velocidad, movimiento y arsenal sin imponer una forma funcional, maneja 600 mil filas en minutos y permite valores SHAP exactos para explicar cada score. Sobre él agregamos un modelo bayesiano jerárquico, estimado con MCMC, para el castigo de altitud por pitcher (sección 6.3).

Capa	Variables que ve	Variables que no ve
Stuff+	Velocidad, spin y eje, IVB, HB, punto de salida, extensión, desvío eje-movimiento, diferencias contra la recta principal del pitcher, manos, altitud del parque	Ubicación, count, etiqueta de tipo de pitcheo
Location+	Ubicación en el plato, count, manos, grupo de pitcheo (recta, rompiente, cambio), altitud	Física del pitcheo
Pitching+	Todo lo anterior más fatiga (número de pitcheo, bateadores enfrentados)	Resultado realizado de la bola en juego

3.1 Objetivos y función de pérdida

Cada capa tiene cinco cabezas, que cubren los objetivos que pide el reto:

Cabeza	Objetivo	Función de pérdida
Desenlace del pitcheo	Bola, strike cantado, whiff, foul, bola en juego, golpeado (de aquí salen swing, whiff, chase y strike cantado)	Log-loss multiclase
Valor del contacto	Carreras esperadas del batazo según velocidad de salida, ángulo y altitud (quita el fildeo y capta el acarreo)	Error cuadrático (L2)
P(rodado)	Rodado dado contacto	Log-loss binaria
P(contacto duro)	Velocidad de salida de 95 mph o más	Log-loss binaria
P(out en juego)	Out esperado según el batazo; P(out) = P(K) + P(bola en juego) · P(out en juego)	Log-loss binaria

El número de árboles se elige con un holdout de 15 % de pitchers y después se reentrena con todos los datos.

3.2 Valor en carreras por count

Sin corredores no se puede usar RE24. Calculamos el valor esperado de cada count con datos LMB y pesos lineales por evento, y definimos el xRV de un pitcheo como el cambio esperado de valor:

$$xRV_i = \Sigma_k \, P(k \mid x_i) \cdot [\, V(c'_k) - V(c_i) \,]$$

donde k recorre los desenlaces, c_i es el count antes del pitcheo y c'_k el estado después del desenlace k (para la bola en juego, el valor del contacto esperado). El baseline del reto es este mismo modelo sin variables del pitcheo.

3.3 Forma sobre etiqueta y arsenal

El clasificador casi no usa "Sweeper" (588 de 635 mil), así que los sweepers quedan mezclados en "Slider". Por eso Stuff+ no recibe la etiqueta de tipo: ve la forma y la diferencia de velocidad, bote, corrida y eje contra la recta principal del mismo pitcher, que son las variables relacionales de arsenal.

3.4 Altitud

La altitud entra como variable continua en metros, así que el modelo aprende de todo el gradiente de la liga (de 10 a 2,240 m). Para trasladar un pitcheo entre ambientes estimamos cuánto se reduce su movimiento con la altura, con los mismos pitchers en parques bajos y altos:

$$mov(h) = mov(0) \cdot e^{(-k \cdot h)}$$

donde h es la altitud en kilómetros y k se estima por tipo de pitcheo y componente. Para la recta, k = 0.13 por km en IVB (queda 75 % del bote en el Harp Helú); para changeup y slider, k ronda 0.20 (queda 61 % a 65 %).

4. La escala Stuff+

Stuff+ es el valor esperado en carreras con signo invertido, estandarizado contra la liga:

$$Stuff+_i = 100 + 10 \cdot (\mu - xRV_i) / \sigma$$

donde μ y σ son la media y la desviación estándar del xRV predicho por la capa en todos los pitcheos. Location+ y Pitching+ usan la misma fórmula con el xRV de su capa. Verificamos que las tres tienen media 100.0 y desviación 10.0 en cada temporada.

1. **Global, no por tipo.** Un 110 en un changeup y un 110 en una recta valen lo mismo en carreras: 10 puntos por pitcheo son unas 1.26 carreras por 100 pitcheos.
2. **Agregación.** El Stuff+ de un pitcher o de un arsenal es el promedio de sus pitcheos. Para comparar pitchers entre ambientes se reestandariza entre pitchers con al menos 300 pitcheos (columnas `*_rel`); el cambio entre ambientes se reporta en puntos de esa escala.
3. **Comparar ambientes.** El mismo pitcheo se evalúa con su movimiento llevado a 0 m y a 2,240 m, con la misma mecánica de release y la misma μ y σ: Δ_i = Stuff+$_i$(2,240 m) − Stuff+$_i$(0 m). Un Δ negativo indica un pitcheo que pierde valor en CDMX.

5. Validación fuera de muestra

El modelo generaliza a temporadas, parques y pitchers que no vio, y agregado por pitcher distingue mucho mejor que el baseline del reto (xRV medio por count). La mejora en log-loss es contra un modelo constante; la de MSE, contra el baseline; r es la correlación por pitcher (200 pitcheos o más) entre xRV predicho y run value real en el conjunto de prueba.

Partición	Capa	Mejora log-loss	Mejora MSE vs baseline	r por pitcher (baseline)
Temporada (2024-25 → 2026)	Stuff	1.5 %	0.2 %	0.42 (−0.26)
Temporada	Location	33.0 %	5.2 %	0.39
Temporada	Pitching	34.8 %	5.6 %	0.56
Parque (resto → Harp Helú)	Stuff	1.4 %	0.3 %	0.66 (−0.20)
Parque	Pitching	34.8 %	5.1 %	0.62
Pitcher (85 % → 15 % de pitchers)	Stuff	1.5 %	0.2 %	0.44 (−0.37)

RMSE. Por pitcheo el run value es casi todo ruido (RMSE de 0.26 a 0.27 carreras para todos los modelos), así que la comparación útil es por pitcher. En run value por 100 pitcheos de pitchers con 200 o más pitcheos, el RMSE del baseline es 1.84 en 2026 y 1.60 en el Harp Helú; Pitching+ lo baja a 1.59 y 1.44, y Stuff+ a 1.75 y 1.53.

Calibración. Ordenamos los pitcheos de 2026 por el xRV que predice Pitching+ y comparamos cada decil con el run value observado (carreras por 100 pitcheos). La pendiente de calibración es 1.00 en temporada y 0.99 en el Harp Helú; en Stuff+, 0.95 y 1.30 (subestima la dispersión en altura).

Decil	1	2	3	4	5	6	7	8	9	10
Predicho	−9.0	−5.1	−3.7	−2.6	−1.2	0.4	2.1	3.7	5.3	12.8
Observado	−9.3	−5.5	−4.0	−3.3	−1.8	−0.5	1.5	3.1	5.3	12.7

Estabilidad y predicción. Stuff+ de un pitcher tiene r año a año de 0.61 y 0.68; su run value observado, 0.23 y 0.29. Pitching+ predice el run value del año siguiente (r = 0.31 y 0.38) mejor que el run value del año anterior. **Efecto altitud:** 150 pitchers con 250 pitcheos o más en parques de 1,800 m o más y de menos de 700 m rinden 1.70 carreras/100 peor en altura; el modelo predice 1.45 (Stuff) y 1.53 (Pitching).

Alcance de la validación: el holdout por pitcher se corrió para la capa Stuff y el de parque solo para el Harp Helú (35 pitchers con 200 pitcheos o más). Los archivos están en `03_validacion_hipotesis/` (`validacion.csv`, `rmse_holdout.csv`, `calibracion_deciles.csv`).

6. Resultados

6.1 Hipótesis

Hipótesis	Veredicto	Evidencia
H1 menos Magnus	Confirmada	Mismo pitcher, Harp Helú contra nivel del mar: recta IVB −4.8 in y HB −3.4 in; changeup HB −5.0 in. Velocidad (+0.2 mph) y spin casi iguales. Queda 75 % del bote de la recta y 61-65 % del movimiento de slider y changeup

Hipótesis	Veredicto	Evidencia
H2 changeup gana valor relativo	No se sostiene	Por forma pierde menos que la recta (−15 contra −22 de Stuff+) pero más que los rompientes (−9). En resultados reales, en el Harp Helú recibe 26 % de contacto duro contra 18 % al nivel del mar, y sus jonrones por 100 pitcheos pasan de 0.70 a 1.16: es el pitcheo cuyo riesgo más crece
H3 rodados valen más	Confirmada	Con igual EV y ángulo, el rodado vale +0.046 carreras más en el Harp Helú y el elevado +0.087. El % de rodados correlaciona r = 0.42 con subir en el ranking del Harp Helú. Lo que gana es el contacto al suelo, no el sinker: como pitcheo pierde 16 puntos
H4 forma sobre etiqueta	Confirmada	Holdout por pitcher: solo velocidad y spin, r por pitcher 0.34; con movimiento, 0.38; forma completa, 0.44. Los "sliders" del clasificador son cuatro formas con Stuff+ de 106 a 112

6.2 Harp Helú contra el nivel del mar, por tipo de pitcheo

Tipo	Stuff+ nivel del mar	Stuff+ Harp Helú	Δ	Δ carreras / 100	Jonrones por 100, Harp Helú / nivel del mar
Slider	110.6	102.0	−8.6	−1.1	0.65 / 0.62
Curva	107.0	98.0	−9.0	−1.1	0.62 / 0.46
Cutter	106.3	96.3	−10.0	−1.3	0.66 / 0.77
Splitter	109.2	97.3	−11.9	−1.5	0.98 / 0.45
Changeup	106.8	91.4	−15.4	−1.9	1.16 / 0.70
Sinker	102.9	86.7	−16.2	−2.0	0.57 / 0.60
Recta (four-seam)	110.0	87.8	−22.3	−2.8	0.81 / 0.71

Por forma, lo que menos pierde es el slider lento de caída (81 mph, IVB −4, HB −14: −7) y lo que más pierde es la recta de 93 mph con mucha corrida (IVB +17, HB +14: −25). Entre parques, el Stuff+ medio de los pitcheos baja de 105-108 en la costa a 92-96 arriba de 1,400

m. En Pitching+, el centro de la zona es lo que más pierde en el Harp Helú (recta al centro −7.1, changeup −7.8); rompientes y cambios abajo y fuera casi no cambian. Por arsenal, el de cutter y slider es el mejor de la liga en el Harp Helú (115 contra 98 al nivel del mar, 13 pitchers).

6.3 Interpretabilidad (SHAP) y castigo por pitcher

Los valores SHAP de Stuff+ (calculados sobre un modelo sustituto que reproduce el xRV con $R^2 = 0.94$) ordenan las variables por puntos de Stuff+ que mueven en promedio: altitud 4.6, diferencia de velocidad con la recta 2.5, desvío eje-movimiento 2.4, velocidad 1.4, movimiento total 1.2; el spin solo mueve 0.7. Las variables relacionales de arsenal pesan más que el spin, en línea con H4.

Para el castigo de altitud de cada pitcher ajustamos un modelo bayesiano jerárquico con MCMC (en la línea de Deshpande y Wyner, 2017). El dato d_j es la diferencia de run value por 100 pitcheos del pitcher-tipo j en parques de 1,800 m o más contra parques de menos de 700 m, con error estándar se_j:

$$d_j \sim N(\theta_j, se_j^2) \quad \theta_j \sim N(a_t + b \cdot pred_j, \tau_t^2)$$

donde $pred_j$ es la pérdida que predice el LightGBM por la forma y t el tipo de pitcheo, con hiperprioris $a_t \sim N(0, 2)$, $b \sim N(1, 0.5)$ y $\tau_t \sim$ HalfNormal(1.5) y parametrización no centrada. Lo muestreamos con PyMC (NUTS), 2 cadenas × 5,000 = 10,000 muestras: R-hat máximo 1.002, 0 divergencias, ESS mínimo 1,686 y autocorrelación de 0.06 o menos en el lag 10. Resultados: b = 0.72 (0.48 a 0.95), así que la forma explica buena parte del castigo real. Hay más evidencia de variación entre pitchers en changeup ($\tau = 1.02$) y cutter (1.10) que en los demás tipos (0.5 a 0.7), aunque los intervalos de τ se traslapan. El castigo posterior medio es 0.9 carreras/100 en el slider, 1.6 en la curva, 1.7 en recta y cutter, 1.8 en el sinker y 2.0 en el changeup; 36 combinaciones pitcher-tipo tienen más de 50 % de probabilidad de perder más de 3 carreras/100. Archivos en `07_modelo_mcmc/`.

7. Estrategias para Diablos en el Harp Helú

Perfil ideal. El pitcher que más rinde en el Harp Helú no depende del Magnus: recta de poco bote ("dead zone") o cutter, slider y curva de mucho spin, alto % de rodados y más de 35 % de rompientes. Correlación con ganar puntos en el ranking del Harp Helú: IVB −0.67, |HB| −0.46, % de rodados +0.42, spin +0.18; los zurdos ganan +1.7 puntos contra −1.2 de los derechos.

1. **Mezcla en casa.** Hoy Diablos sube la recta en casa (33 % contra 30 % de visita) y baja el slider (17.7 % contra 23.8 %); solo el cutter va en la dirección correcta (10.8 % contra 4.9 %). Recomendamos bajar la recta 5 a 10 puntos porcentuales y recuperar el slider. `02_diablos/diablos_arsenal.csv` lo detalla por pitcher.
2. **Changeup como pitcheo de sorpresa.** Por su riesgo de jonrón en altura, en casa debe ir abajo y fuera de la zona; si se usa, el firme y de poco fade pierde menos (−12 contra −17).
3. **Orillas y abajo.** La recta, si va, arriba de la zona o en las esquinas, nunca al centro.
4. **Rodados y defensa de cuadro.** El elevado cuesta casi el doble en altura.
5. **Rotación y bullpen por sede.** Abrir en casa con pitcher_00619 (Pitching+ en ambiente Harp Helú 137, el mejor de la liga), pitcher_01060 (124) y pitcher_00778 (abridor zurdo, +11 puntos en altura); pitcher_00069 rinde mejor de visita (−13). En el bullpen de casa, más entradas para pitcher_01099 (+22 puntos), pitcher_00430 (+15), pitcher_01018 (+14), pitcher_00586 (+12) y pitcher_00315 (+12); de visita, pitcher_00445 (−15), pitcher_00083 (−9) y pitcher_00573 (−8).
6. **Reclutamiento.** Evaluar refuerzos con Pitching+ en ambiente Harp Helú (`pitching_plus_hh_rel`), no con su Stuff+ al nivel del mar, y revisar su castigo bayesiano (`07_modelo_mcmc/`), sobre todo en changeup y cutter: si P(castigo > 3 carreras/100) supera 50 %, ese pitcheo no debe ser su arma en casa. El top 30 de la liga para el Harp Helú está en `02_diablos/top30_liga_para_harp_helu.csv`.

8. Simulador, alcance y limitaciones

El simulador (`04_simulador/simulador_standalone.html`, abre sin internet) usa los modelos finales de Stuff+ de este documento, con la misma μ y σ. El pitching coach ingresa velocidad, spin, eje, punto de salida y movimiento de un pitcheo y obtiene su Stuff+ en el Harp Helú y al nivel del mar lado a lado, con un mapa de movimiento IVB × HB de los pitcheos más y menos efectivos. La misma función está en `06_codigo/modelo/stuffplus.py` (`ModeloStuff().comparar(pitch)`).

- **Estadio inferido.** El Harp Helú se identificó por récord y continuidad de pitchers. Algunos equipos de baja confianza pueden estar intercambiados entre sí, siempre dentro de la misma categoría de altitud.
- **Traslado de movimiento.** Los k de changeup y slider (cerca de 0.20 por km) son el doble de lo que explicaría solo la densidad del aire; puede haber efectos de costura, de selección o de calibración de Trackman por parque.

- **Física contra resultados.** Por forma, la recta debería perder más que el changeup; en resultados reales pierden parecido (1.7 y 2.0 carreras/100). Las recomendaciones combinan ambas fuentes.
- **Sin corredores, clima ni umpire.** El valor en carreras es por count, sin estado base-out, y la altitud no captura temperatura, humedad ni viento.
- **Poco poder a nivel pitcheo.** Stuff+ mejora poco por pitcheo; su utilidad está en la agregación y la estabilidad.

Referencias

- Brill, R. S., Deshpande, S. K. y Wyner, A. J. (2022). A Bayesian analysis of the time through the order penalty in baseball. arXiv:2210.06724.
- Deshpande, S. K. y Wyner, A. J. (2017). A hierarchical Bayesian model of pitch framing. arXiv:1704.00823.
- McBride, M. (2026). Measuring pitcher production fairly using the Shapley Value. *Games*, 17(2), 15.
- Nathan, A. M. (2008). The effect of spin on the flight of a baseball. *American Journal of Physics*, 76(2), 119-124.
- Richardson, E. (2014). High Altitude Offense. *Baseball Research Journal*, SABR.

Datos: pitcheo a pitcheo LMB 2024-2026 (Trackman), proporcionados por ISAC con IDs anonimizados.