EDA: datos LMB y efecto de la altitud

Hackathon Diablos Rojos · Stuff+ calibrado al Estadio Alfredo Harp Helú (2,240 m) · 18 de octubre de 2026

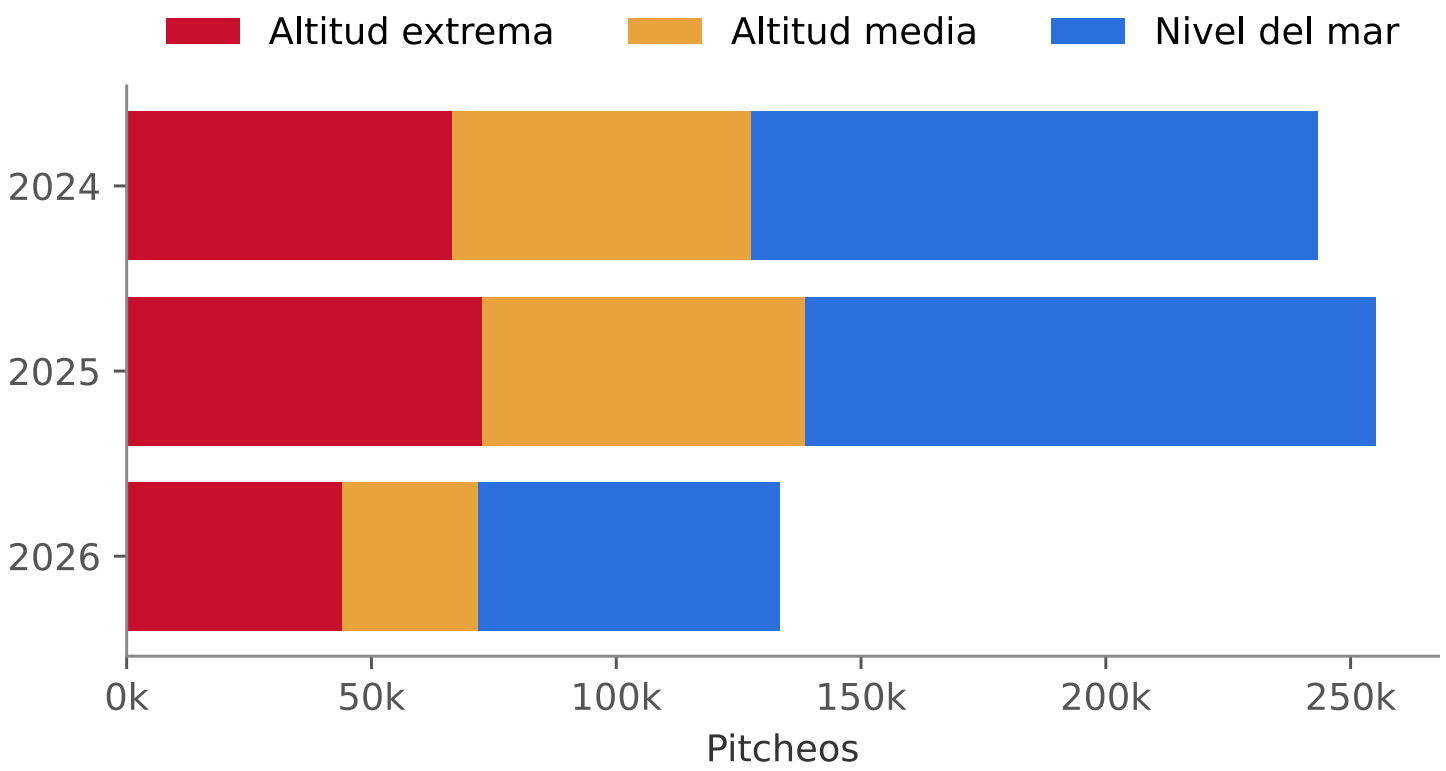
En una página

- Antes de cualquier modelo, los datos ya muestran el efecto de la altitud: entre más alto el estadio, **menos se mueve la recta** (r = -0.98) y **más lejos vuela el elevado** (r = 0.97).
- La recta pasa de ~17.5 pulgadas de bote inducido en la costa a 12.2 en el Harp Helú; el elevado promedio, de ~289 a 324 pies.
- La velocidad y el giro casi no cambian con la altitud (r = 0.42 y -0.08). La pelota sale igual; lo que cambia es cuánto la empuja el aire (efecto Magnus).
- El contacto duro sube con la altitud (r = 0.71), pero los jonrones por bola en juego casi no (r = 0.38).
- Estas observaciones definen el modelo: altitud continua en metros, forma completa del pitcheo en vez de solo giro, y una cabeza aparte para el valor del contacto.

1. Los datos

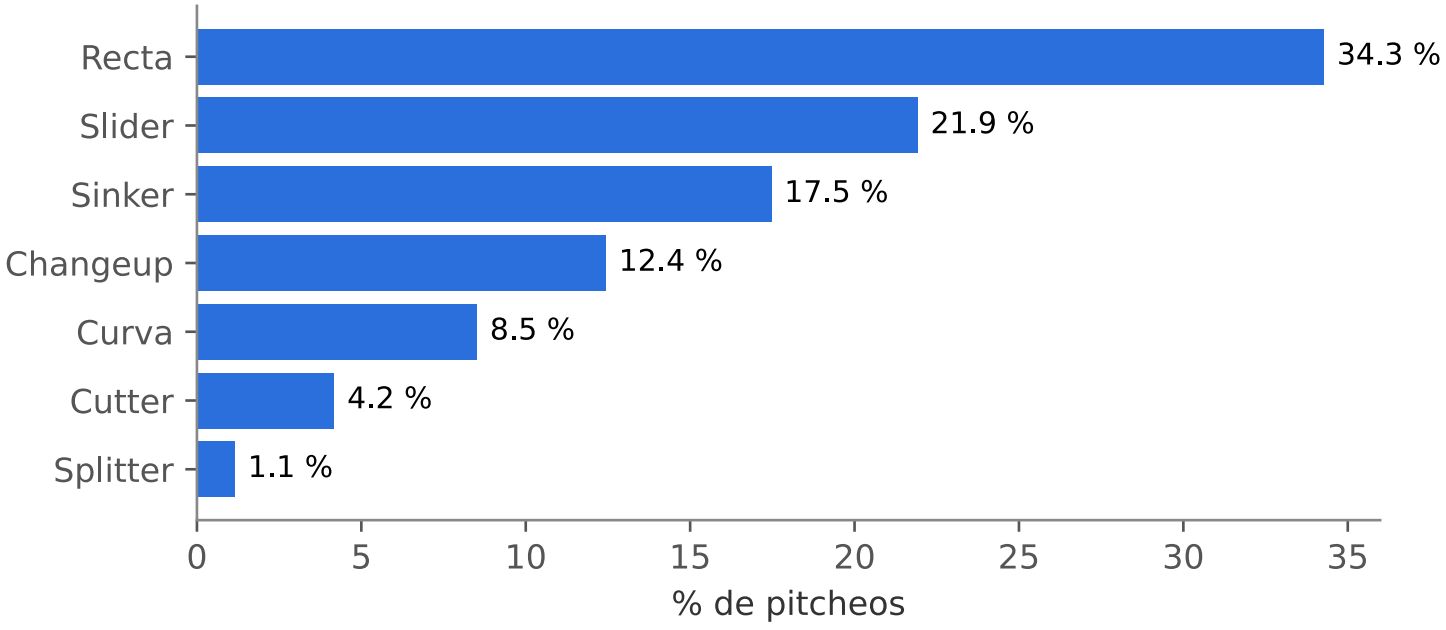
635,002	2,127	1,134	864	20
pitcheos Trackman	juegos	pitchers	bateadores	estadios

Tres temporadas de la LMB (2024, 2025 y 2026 parcial). Cerca de la mitad de los pitcheos se lanzó en parques con altitud, lo que permite comparar al mismo pitcher en distintos entornos.



Pitcheos por temporada y categoría de altitud. Fuente: volumen_temporada_altitud.csv.

2. Mezcla de pitcheos



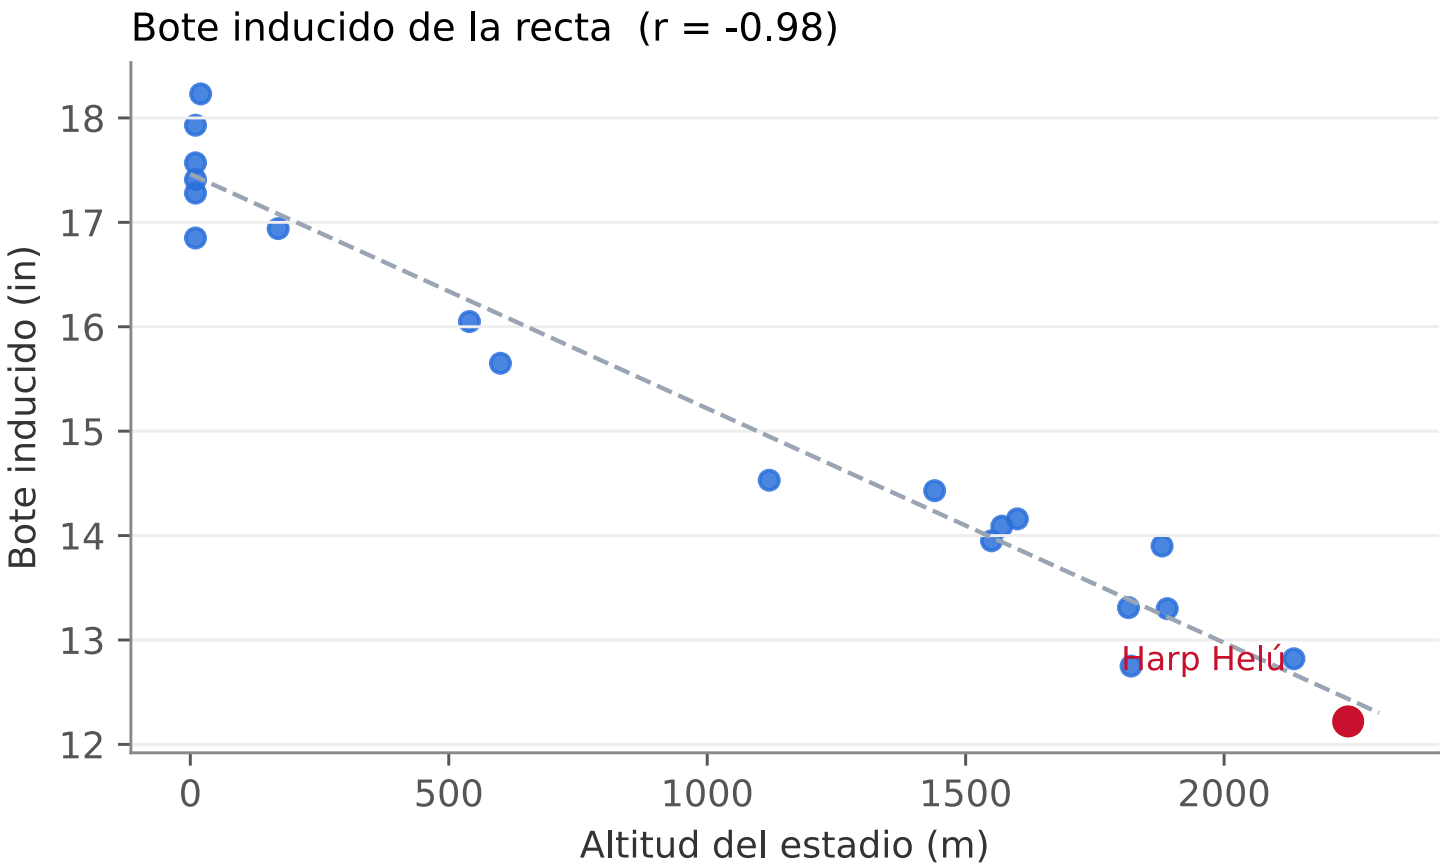
Participación por tipo (AutoPitchType). Fuente: mezcla_pitcheos.csv.

El clasificador casi no usa «Sweeper» (0.1 %), así que los sweepers quedan dentro de «Slider». Por eso el modelo mira la forma del pitcheo y no la etiqueta.

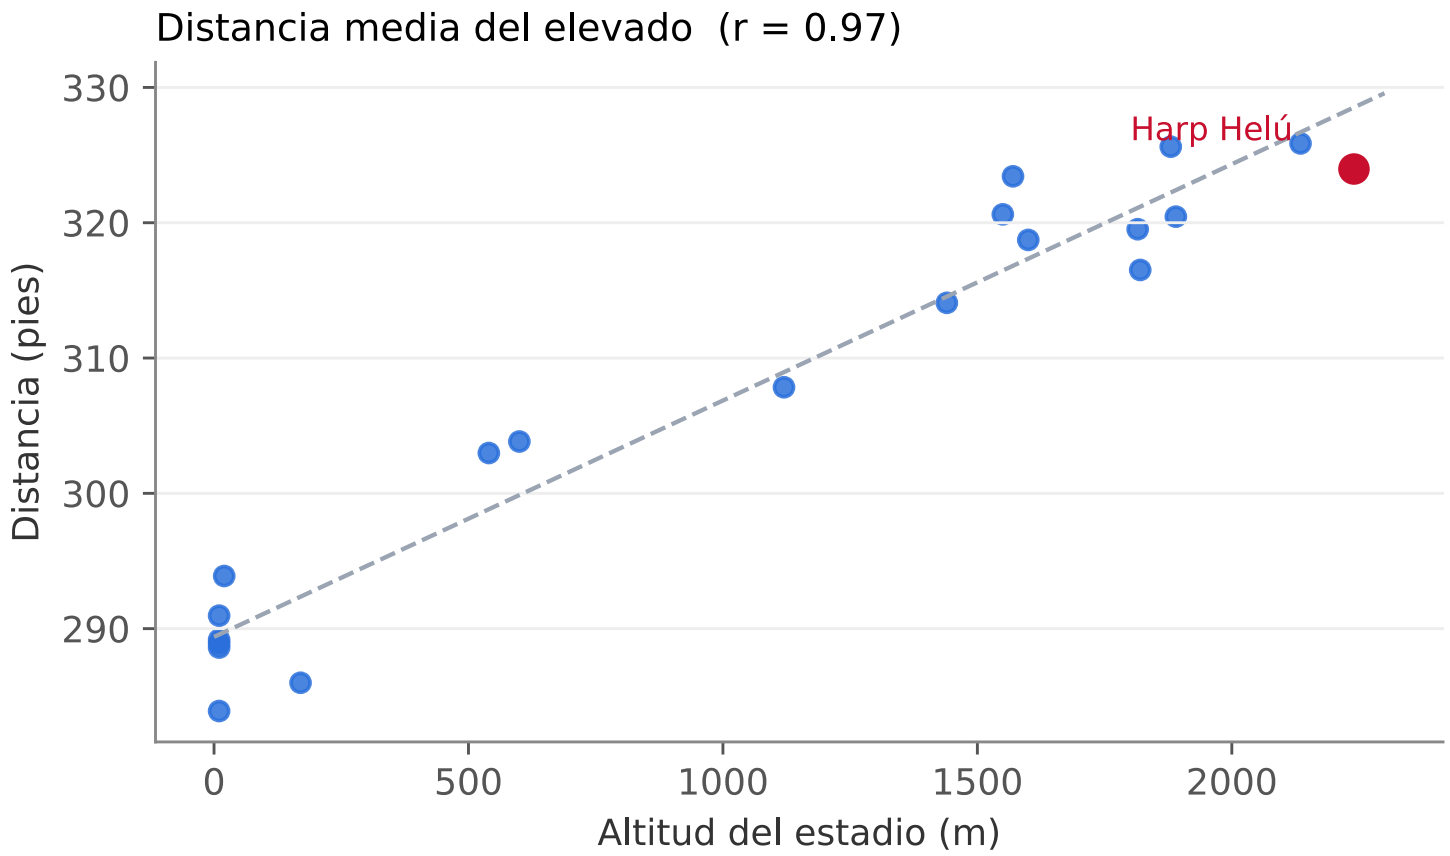
3. Calidad de datos

- No hay ID de estadio, solo la categoría de altitud. El estadio de cada juego se infirió por equipo local (récords 2024-2025 y altitud de la ciudad); el Harp Helú es la casa del equipo con mejor récord. Es una inferencia, no un dato confirmado por ISAC.
- No hay corredores en base, fecha, umpire ni clima. Por eso el valor en carreras se calcula por cuenta (balls-strikes) y no con RE24.
- `is_hit_by_pitch` viene siempre en 0 aunque hay golpeados; se recalcula desde PitchCall.
- 6,669 pitcheos con PlateLocHeight = 0 exacto (se tratan como faltantes), 3,272 sin ID de pitcher y 2,834 sin estadio asignado.
- `EffectiveVelo` llega como texto y se convierte a número.

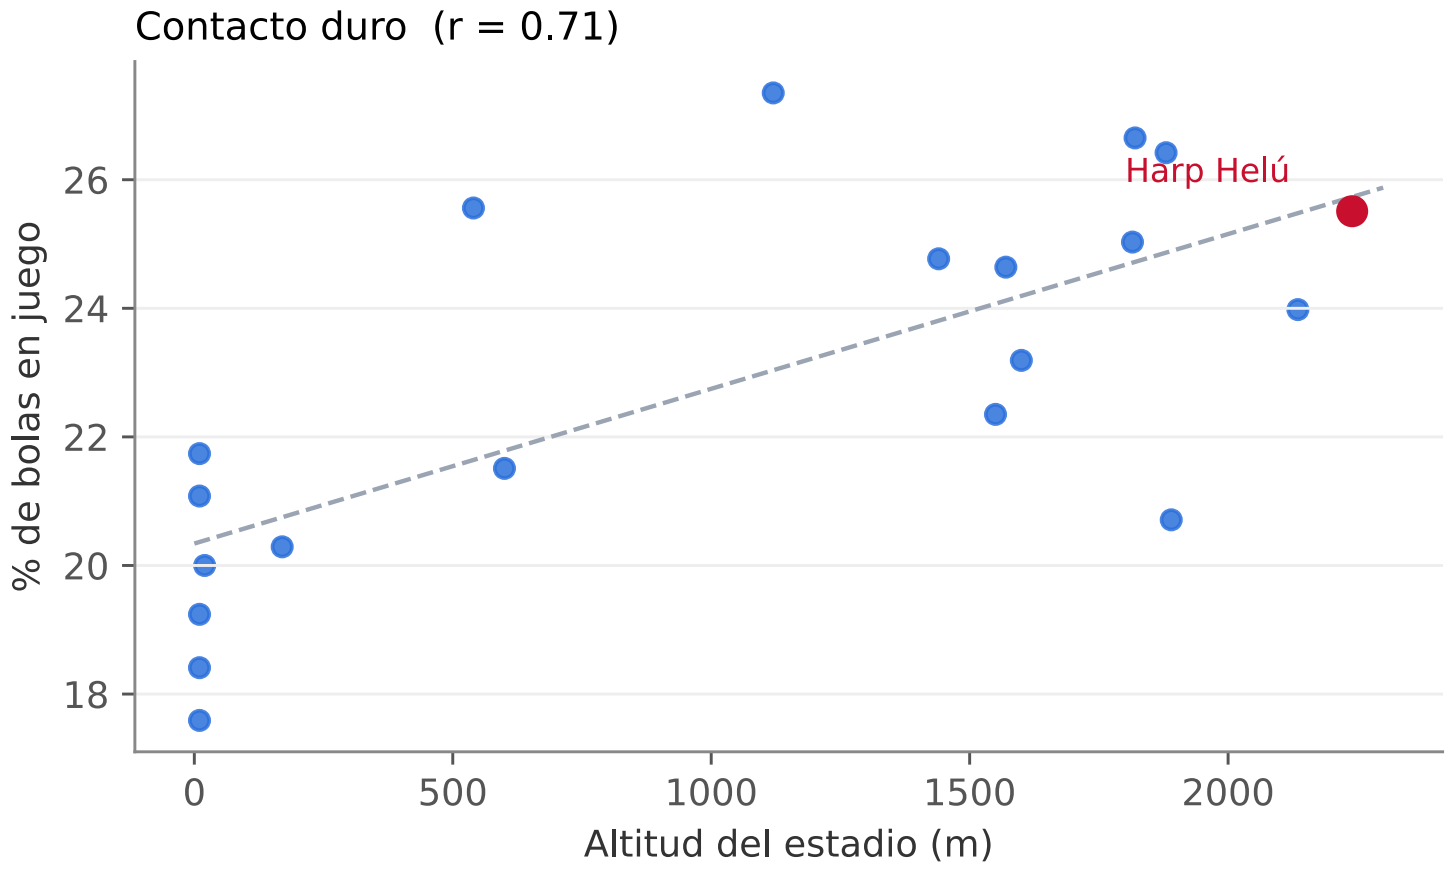
4. La altitud en crudo, por estadio



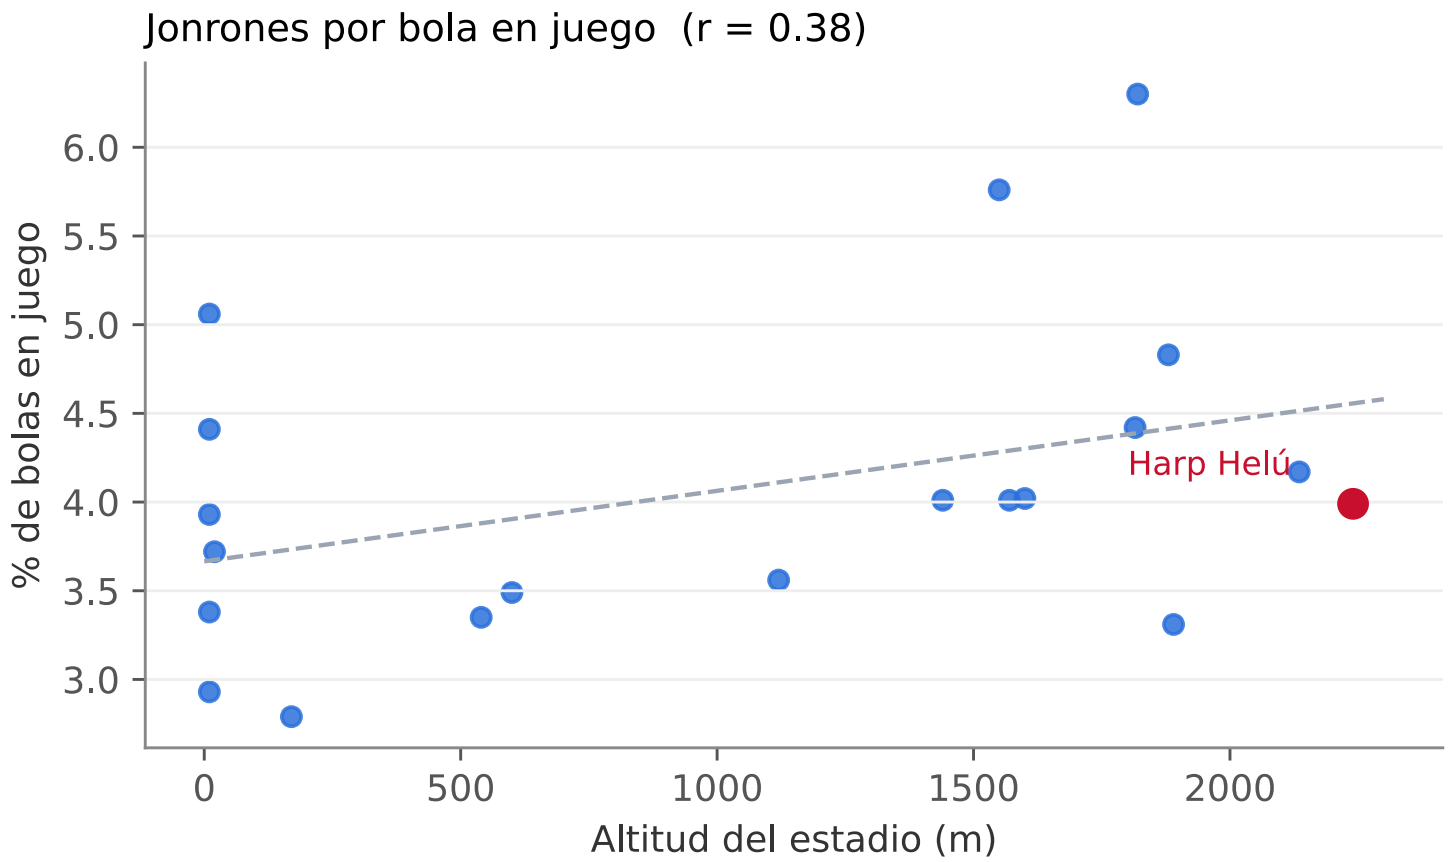
Bote inducido medio de las rectas en cada estadio, 2024-2026. Rojo: Harp Helú. Línea punteada: ajuste lineal.



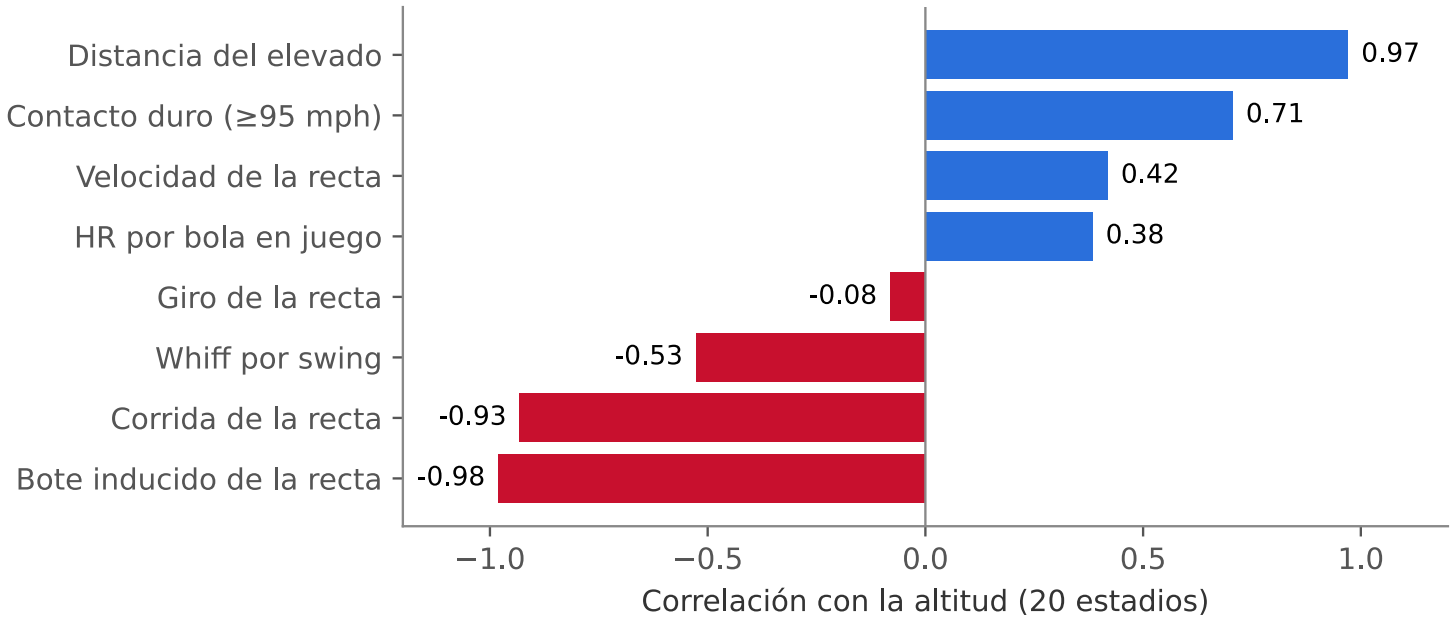
Distancia media de los elevados (FlyBall) por estadio.



Contacto duro: % de bolas en juego con velocidad de salida ≥ 95 mph.



Jonrones por bola en juego. La relación es débil: el exceso de ofensiva en altura viene más de hits que de jonrones (en línea con Richardson, 2014).



Correlación de cada métrica con la altitud entre los 20 estadios. Fuente: correlacion_con_altitud.csv.

Tabla por estadio

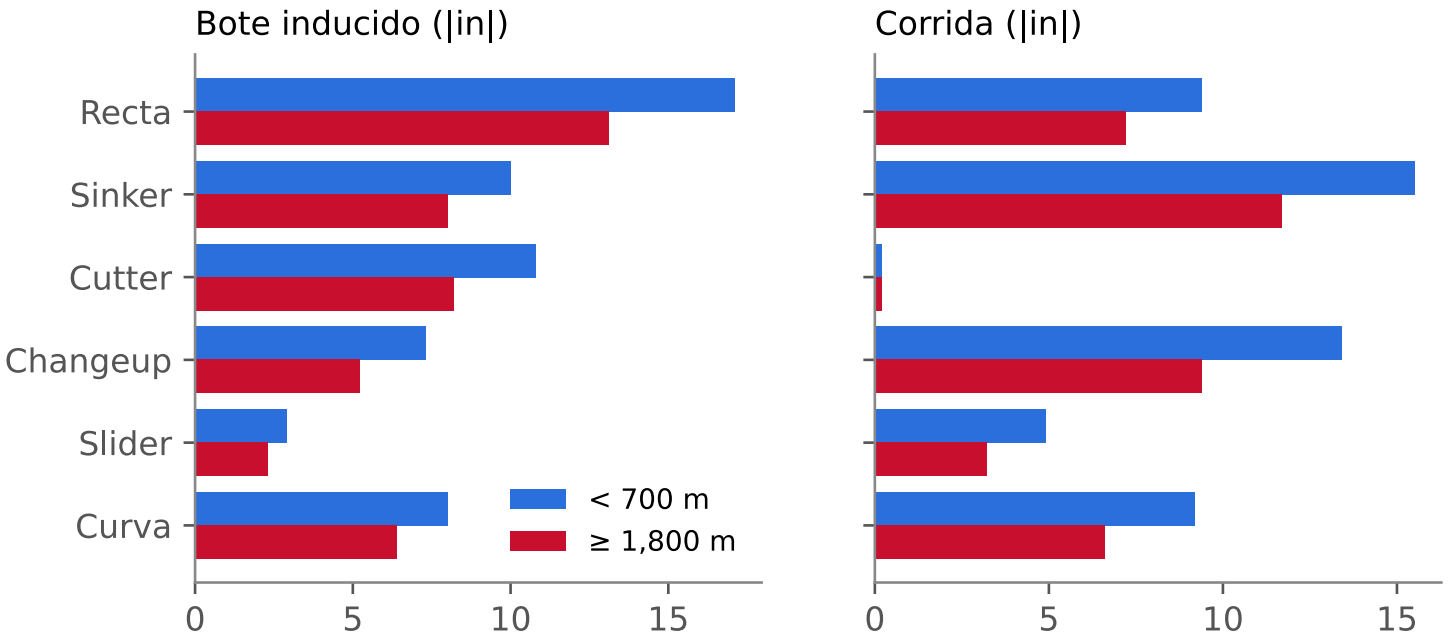
Estadio	Altitud (m)	Pitcheos	IVB recta (in)	HB recta (in)	Velo recta (mph)	Giro recta (rpm)	Contacto duro %	Dist. elevado (ft)	HR/BIP %	Whiff/swing %
Estadio Beto Ávila	10	27,839	17.6	9.8	90.9	2,335	19.2	284	3.9	26.2
Estadio Nelson Barrera	10	32,199	17.9	9.8	90.6	2,344	17.6	289	5.1	26.6
Parque Deportivo Veracruzano	10	33,347	17.3	9.5	91.3	2,365	18.4	289	4.4	24.0
Parque Centenario 27 de Febrero	10	28,401	17.4	9.0	92.1	2,364	21.7	289	3.4	23.8
Parque Kukulcán	10	33,983	16.9	8.7	91.0	2,337	21.1	291	2.9	23.1
Estadio Chevron	20	34,168	18.2	9.9	91.7	2,305	20.0	294	3.7	28.7
Estadio Nuevo Laredo	170	36,005	16.9	9.6	92.2	2,330	20.3	286	2.8	25.1
Estadio Mobil Super	540	37,373	16.1	9.6	92.2	2,328	25.6	303	3.4	23.0
Estadio Monclova	600	31,634	15.7	8.3	92.1	2,168	21.5	304	3.5	22.8
Estadio Revolución	1,120	38,761	14.5	7.6	92.1	2,355	27.4	308	3.6	23.7
Estadio Monumental	1,440	21,991	14.4	7.6	91.4	2,317	24.8	314	4.0	24.1
Estadio Eduardo Vasconcelos	1,550	33,622	13.9	7.3	92.1	2,335	22.4	321	5.8	24.9
Estadio Panamericano	1,570	31,712	14.1	7.5	91.7	2,327	24.6	323	4.0	24.4
Estadio Francisco I. Madero	1,600	29,087	14.2	7.6	91.6	2,339	23.2	319	4.0	22.7
Estadio Domingo Santana	1,815	35,273	13.3	7.0	92.1	2,316	25.0	320	4.4	23.4
Estadio Querétaro	1,820	10,156	12.8	6.8	91.5	2,314	26.6	317	6.3	22.4
Parque Alberto Romo Chávez	1,880	28,572	13.9	7.5	92.0	2,333	26.4	326	4.8	21.9

Estadio	Altitud (m)	Pitcheos	IVB recta (in)	HB recta (in)	Velo recta (mph)	Giro recta (rpm)	Contacto duro %	Dist. elevado (ft)	HR/BIP %	Whiff/swing %
Estadio Francisco Villa	1,890	35,394	13.3	7.2	91.7	2,328	20.7	320	3.3	24.7
Estadio Hermanos Serdán	2,135	33,330	12.8	7.3	92.0	2,349	24.0	326	4.2	22.5
Estadio Alfredo Harp Helú	**2,240**	**39,321**	**12.2**	**6.9**	**92.2**	**2,285**	**25.5**	**324**	**4.0**	**23.2**

Fuente: efecto_altitud_por_estadio.csv. Corrida (HB) con zurdos espejados.

5. Por tipo de pitcheo

En parques de 1,800 m o más todos los pitcheos se mueven menos que en parques de menos de 700 m, mientras la velocidad y el giro no cambian. Son promedios crudos que mezclan pitchers distintos; el modelo compara al mismo pitcher.



Movimiento absoluto por tipo, parques altos contra bajos. Fuente: movimiento_por_tipo_alto_vs_bajo.csv.

Pitcheo	IVB alto / bajo (in)	HB alto / bajo (in)	Velo alto / bajo (mph)	Giro alto / bajo (rpm)
Recta	13.1 / 17.1	7.2 / 9.4	92.0 / 91.6	2,320 / 2,320
Sinker	8.0 / 10.0	11.7 / 15.5	91.4 / 91.1	2,266 / 2,246
Cutter	8.2 / 10.8	0.2 / 0.2	88.6 / 88.3	2,355 / 2,425
Changeup	5.2 / 7.3	9.4 / 13.4	83.0 / 83.4	1,835 / 1,802
Slider	2.3 / 2.9	-3.2 / -4.9	84.0 / 83.3	2,432 / 2,398
Curva	-6.4 / -8.0	-6.6 / -9.2	77.8 / 77.5	2,545 / 2,519

La recta pierde 4 pulgadas de bote; el sinker y el changeup, 4 de corrida. El slider pierde poco en pulgadas porque se mueve poco desde el inicio.

6. Qué decisiones del modelo salen del EDA

Lo que muestra el EDA	Decisión de modelado
El movimiento cae de forma continua con la altitud (r = -0.98 en la recta), no solo en el Harp Helú	La altitud entra como variable continua en metros
Velocidad y giro no cambian; el movimiento sí	Se modela la forma completa (movimiento, eje, separación con la recta) y no solo el giro (H4)
El elevado viaja ~35 pies más arriba de 1,800 m	Una cabeza aparte para el valor del contacto según velocidad, ángulo y altitud (H3)
Los pitchers lanzan en varios entornos	Comparaciones dentro del mismo pitcher y un modelo bayesiano jerárquico (MCMC) que usa su historia en altura
El clasificador mete sweepers en «Slider»	Stuff+ no recibe la etiqueta del tipo, solo la forma
No hay corredores ni estadio	Valor en carreras por cuenta; estadio inferido por equipo local

Código: eda_altitud.py. Todos los CSV están en la misma carpeta eda_modelo.